

TRABALHO CLASSIFICAÇÃO DE IMAGENS

Iniciamos com a base de dados crua, extraímos features utilizando Inception_v3 e separamos em 80/20. Utilizamos 20% para encontrar os melhores hiperparâmetros e então treinamos os modelos com os restantes 80%. Abaixo segue a taxa de acerto média entre os folds para cada modelo.

Taxas de Acerto (%)

Taxa de Acerto Média	
	Validação Cruzada (5 folds)
KNN (parâmetros)	92%
Árvore Decisão (parâmetros)	67%
SVM (parâmetros)	97%
Naive Bayes	92%
MLP	96%
Random Forest	96%
Bagging	95%
Xgboost	95%
AdaBoost	80%

Melhor modelo

O modelo que obteve a melhor performance foi o SVM com uma acurácia de 97% na validação cruzada com 5 folds.

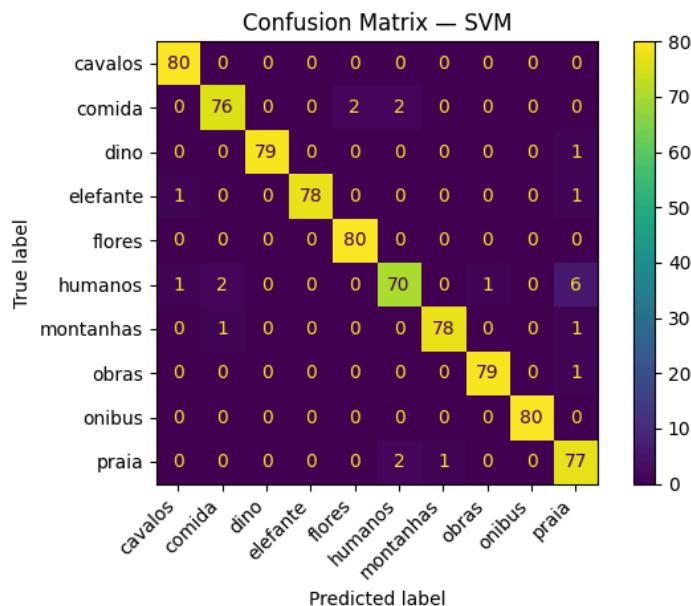


Figura 1: Matrix de confusão da SVM.

Exemplos de erros do modelo.

Analisando alguns dos erros dos modelos, podemos observar algumas coisas interessantes:



Figura 2: Real: Humano
Previsto: Praia



Figura 3: Real: Comida
Previsto: Flores



Figura 4: Real: Elefante
Previsto: Praia

No caso da Figura 2, o modelo identificou o que aparenta ser uma imagem com a classificação incorreta. Já na Figura 3, podemos observar que certas características da imagem remetem às flores (cores vibrantes, fundo com folhas verdes) o que pode ter gerado um embedding similar ao de flores. Finalmente, na Figura 4 observamos um erro mais difícil de ser racionalizado, é possível que a areia e água presentes na imagem levaram à esta classificação, no entanto é impossível dizer.

Considerações Finais

Como a Inception_v3 fundamentalmente transforma as imagens em vetores o problema se torna separar esses vetores em suas respectivas classes, algo que a SVM lida bem por ser capaz de dividir esse espaço de alta dimensão. No entanto, erros ocorrem em casos como na Figura 3 onde o vetor tem uma maior ambiguidade. Portanto, a SVM lida bem com problemas com alta distinção e menor ambiguidade entre as classes.